

LLM Notes

2026 Spring

Day 11: CS336 AdamW

Deep Learning

主讲: Aaron

Fudan University

今日摘要

对于 AdamW 的基础原理不做过多介绍, 主要记录使用 AdamW 训练 Transformer LM 时的显存、FLOPs 与训练时间核算。

11.1 AdamW 资源核算

定义

定义 11.1.1 (符号约定). 使用 B 表示 batch size, V 表示 vocabulary size, S 表示 context length, L 表示 Transformer Block 数量, $d = d_{\text{model}}$ 表示模型维度, h 表示 attention head 数量, 并记

$$d_{\text{head}} = \frac{d}{h}, \quad d_{\text{ff}} = \frac{8}{3}d.$$

所有 Tensor 均假设使用 FP32, 因此每个标量占用 4 bytes。

11.1.1 问题 (a): 训练峰值显存

训练时的峰值显存分为四部分:

$$M_{\text{total}} = M_{\text{parameters}} + M_{\text{activations}} + M_{\text{gradients}} + M_{\text{optimizer}}.$$

11.1.1.1 模型参数

需要统计:

- token embedding; $V \times d$
- L 个 Transformer Block; (x)
- final RMSNorm; d

- language-model head。 $V*d$

单个 Transformer Block 包含:

- Q、K、V 和 output projection; $4*d*d$
- 两个 RMSNorm; $2*d$
- SwiGLU 的 W_1, W_2, W_3 。 $3*8/3*d*d = 8*d*d$

分析

模型参数量记为

$$N_{\text{parameters}} = L(12d^2 + 2d) + 2Vd + d = [L(12d + 2) + 2V + 1]d.$$

参数显存为

$$M_{\text{parameters}} = 4N_{\text{parameters}} \text{ bytes.}$$

11.1.1.2 梯度

每个可训练参数通常对应一个同形状的梯度 Tensor。

分析

$$N_{\text{gradients}} = N_{\text{parameters}},$$

因此

$$M_{\text{gradients}} = 4N_{\text{gradients}} \text{ bytes.}$$

11.1.1.3 AdamW 优化器状态

AdamW 为每个参数保存:

$$m_t \quad \text{和} \quad v_t,$$

分别表示梯度的一阶矩估计与二阶矩估计。

分析

$$N_{\text{optimizer}} = 2N_{\text{gradients}},$$

因此

$$M_{\text{optimizer}} = 8N_{\text{gradients}} \text{ bytes.}$$

每个参数对应的步数 t 只占少量标量内存，可以忽略。

11.1.1.4 Activation

每个 Transformer Block 中:

1. 2 个 RMSNorm 的输出; $(2BSd)$
2. Q、K、V projections; $(3BhSd_{head})$
3. QK^T ; $(BhSS)$
4. softmax attention matrix; $(BhSS)$
5. attention weights 与 V 相乘的结果; $(BhSd_{head})$
6. output projection; (BSd)
7. SwiGLU 的 W_1 投影; (BSd_{ff})
8. SwiGLU 的 W_3 投影; (BSd_{ff})
9. gate 分支的 SiLU 输出; (BSd_{ff})
10. 两个分支逐元素相乘的结果; (BSd_{ff})
11. SwiGLU 的 W_2 输出。 (BSd)

整个模型还包括:

- final RMSNorm; (BSd)
- lm head 产生的 logits; (BSV)
- cross-entropy 在 logits 上产生的中间结果。 (BSV)

分析

$$N_{\text{activations}} = B \left[L \left(\frac{56}{3} Sd + 2hS^2 \right) + Sd + 2SV \right]$$

由于所有 activation 均使用 FP32, 其显存占用为

$$M_{\text{activations}} = 4B \left[L \left(\frac{56}{3} Sd + 2hS^2 \right) + Sd + 2SV \right] \text{ bytes.}$$

11.1.1.5 总峰值显存

分析

$$\begin{aligned} M_{\text{total}} &= M_{\text{parameters}} + M_{\text{gradients}} \\ &\quad + M_{\text{optimizer}} + M_{\text{activations}}. \end{aligned}$$

训练峰值显存为

$$\begin{aligned} M_{\text{total}} &= M_{\text{parameters}} + M_{\text{gradients}} + M_{\text{optimizer}} + M_{\text{activations}} \\ &= 16N_{\text{parameters}} + 4N_{\text{activations}}. \end{aligned}$$

代入参数量与 activation 数量:

$$\begin{aligned} M_{\text{total}} &= 4 \left\{ 4d [L(12d + 2) + 2V + 1] \right. \\ &\quad \left. + B \left[L \left(\frac{56}{3} Sd + 2hS^2 \right) + Sd + 2SV \right] \right\} \text{ bytes.} \end{aligned}$$

也可以整理为

$$\begin{aligned} M_{\text{total}} &= 16d [L(12d + 2) + 2V + 1] \\ &\quad + 4B \left[L \left(\frac{56}{3} Sd + 2hS^2 \right) + Sd + 2SV \right] \text{ bytes.} \end{aligned}$$

备注

本题只统计题目指定的 Tensor，不考虑 CUDA workspace、显存碎片、PyTorch allocator 预留空间和其他框架开销，因此结果是理论估计值。

11.1.2 问题 (b): GPT-2 XL 与最大 Batch Size

代入 GPT-2 XL 配置：

$$V = 50,257,$$

$$S = 1,024,$$

$$L = 48,$$

$$d = 1,600,$$

$$h = 25,$$

$$d_{\text{ff}} = 4,288.$$

显存限制为：

$$M_{\text{max}} = 80 \text{ GB}.$$

分析

将问题 (a) 的结果代入并整理为

$$M_{\text{total}}(B) = \boxed{aB + b}.$$

其中：

$$a = 16.36 \text{ GB} (\text{每增加一个 batch 样本所需的 activation 显存}),$$

$$b = 26.27 \text{ GB} (\text{参数、梯度和优化器状态等固定显存}).$$

最大 batch size 满足：

$$aB + b \leq 80 \text{ GB}.$$

因此：

$$B_{\text{max}} = \left\lfloor \frac{80 \text{ GB} - b}{a} \right\rfloor = 3.$$

11.1.3 问题 (c): AdamW 单步 FLOPs

对每一个参数元素，AdamW 依次执行：

1. weight decay:

$$\theta \leftarrow \theta - \alpha \lambda \theta;$$

2. 更新一阶矩:

$$m \leftarrow \beta_1 m + (1 - \beta_1)g;$$

3. 更新二阶矩:

$$v \leftarrow \beta_2 v + (1 - \beta_2)g^2;$$

4. 自适应参数更新:

$$\theta \leftarrow \theta - \alpha_t \frac{m}{\sqrt{v} + \epsilon}.$$

分析

逐元素计算量:

操作	FLOPs / parameter
weight decay	2
first moment update	3
second moment update	4
parameter update	5
合计	14

若模型共有 $N_{\text{parameters}}$ 个参数, 则

$$F_{\text{AdamW step}} = 14N_{\text{parameters}}.$$

11.1.4 问题 (d): H100 训练时间与 MFU

$$F_{\text{peak}} = 495 \text{ TFLOP/s},$$

$$\text{MFU} = 50\%,$$

$$B = 1,024,$$

$$T = 400,000 \text{ steps}.$$

H100 的有效吞吐率为:

$$F_{\text{effective}} = F_{\text{peak}} \times \text{MFU} = 247.5 \text{ TFLOP/s}.$$

设一条长度为 S 的序列进行一次 forward 的 FLOPs 为:

$$F_{\text{forward}}.$$

题目假设 backward FLOPs 是 forward 的两倍:

$$F_{\text{backward}} = 2F_{\text{forward}}.$$

因此一次完整训练计算为:

$$F_{\text{forward+backward}} = 3F_{\text{forward}}.$$

分析

一个 batch 的模型计算量为:

$$F_{\text{batch}} = 3BF_{\text{forward}}.$$

全部训练步骤的模型计算量为:

$$F_{\text{training}} = 3BT F_{\text{forward}}.$$

训练时间为:

$$t_{\text{seconds}} = \frac{3BT F_{\text{forward}}}{F_{\text{effective}}}.$$

换算为小时:

$$t_{\text{hours}} = \frac{3BT F_{\text{forward}}}{3600 F_{\text{effective}}} = \frac{3 * 1024 * 400k * 3.52 * 10^{12}}{3600 * 247.5 * 10^{12}} = 4850.$$