

LLM Notes

2026 Spring

Day 14: Mixed Precision 与 Autocast

CS336 Systems

主讲: Aaron

Fudan University

今日摘要

2026.7.16 现在做到了 cs336 chapter2 混合精度的部分, 主要是使用 autocast 自动适当地使用 bf16 进行一些中间结果运算, 从而小幅度减小显存占用, 大幅加速训练

14.1 浮点误差的累积

分别使用 FP32 和 FP16 累加 1000 次 0.01, 得到:

累加方式	最终结果
FP32 accumulator + FP32 value	10.0001
FP16 accumulator + FP16 value	9.9531
FP32 accumulator + FP16 value	10.0021

FP16 accumulator 的误差最大, 因为每次加法都需要舍入到 FP16。使用 FP32 accumulator 可以减少累加过程中的误差, 但无法恢复 0.01 转换成 FP16 时已经损失的精度。

14.2 Autocast 的作用

```
with torch.autocast(  
    device_type="cuda",  
    dtype=torch.bfloat16,  
):  
    logits = model(inputs)  
    loss = cross_entropy(logits, targets)
```

autocast 根据算子的数值稳定性和硬件实现, 自动选择计算精度:

- 矩阵乘法和 Linear 通常使用 BF16 或 FP16;
- normalization、reduction 和 loss 等敏感运算可能使用 FP32;
- 模型参数本身仍然保存为 FP32;
- 参数梯度通常也累积为 FP32。

它改变的是算子的计算 dtype，而不是永久修改模型参数的存储 dtype。

14.2.1 ToyModel 实验

在 FP16 autocast 下观察到:

对象	dtype
模型参数	<code>torch.float32</code>
Linear 输出	<code>torch.float16</code>
ReLU 输出	<code>torch.float16</code>
LayerNorm 输出	<code>torch.float32</code>
最终 logits	<code>torch.float16</code>
Cross-entropy loss	<code>torch.float32</code>
参数梯度	<code>torch.float32</code>

这说明一个模型内部可以同时存在多种 dtype。数据类型由当前算子的 autocast policy 决定，并不是进入 autocast 后所有 tensor 都变成低精度。

分析

Linear 的主要工作是矩阵乘法，适合在低精度 Tensor Core 上执行。Loss 和部分 normalization/reduction 对数值误差更敏感，因此通常保留或返回 FP32 结果。

14.3 FP32 与 BF16 Benchmark

实验设置为 batch size 4、sequence length 512，每组进行 5 次 warmup 和 10 次正式测量。

模型	Forward / ms		Forward+Backward / ms	
	FP32	BF16	FP32	BF16
Small	20.10	9.13	62.87	35.15
Medium	55.21	22.23	170.32	72.90
Large	124.12	41.29	386.51	131.87
XL	334.33	72.86	1068.91	243.37

对应的 BF16 加速比约为：

模型	Forward speedup	Forward+Backward speedup
Small	2.20×	1.79×
Medium	2.48×	2.34×
Large	3.01×	2.93×
XL	4.59×	4.39×

模型越大，矩阵乘法越能充分利用 Tensor Core，因此 BF16 的加速效果整体上更加明显。实际加速比不仅取决于理论 FLOPs，还取决于矩阵形状、kernel efficiency、非矩阵算子的占比和 GPU 利用率。

10B-shaped 模型的 forward 也成功运行：

$$T_{\text{FP32}} = 1292.79 \text{ ms}, \quad T_{\text{BF16}} = 190.78 \text{ ms}.$$

但两种精度的 forward+backward 都发生了 OOM。

14.4 为什么 BF16 Autocast 没有让显存减半

当前实验使用的是 BF16 autocast，而不是把模型参数整体转换为 BF16：

- FP32 参数仍占每个参数 4 bytes；
- 参数梯度通常仍为 FP32；
- AdamW 的一阶矩和二阶矩通常仍为 FP32；
- 主要减少的是部分中间 activation 和临时 tensor；
- 某些数值敏感算子仍会产生 FP32 activation。

因此，autocast 可以显著加速矩阵计算，并降低一部分 activation memory，但不会自动将参数、梯度和 optimizer states 的显存全部减半。

今日摘要

本节的主要结论如下：

1. 低精度表示和低精度累加都会引入误差；
2. autocast 按算子选择 dtype，而不是转换整个模型；
3. 参数和梯度可以保持 FP32，中间矩阵计算使用 BF16；

4. BF16 对较大 Transformer 的加速更加明显；
5. BF16 autocast 主要减少部分 activation memory，不会自动将完整训练状态的显存减半。