

LLM Notes

2026 Spring

Day 16: Nsight Systems 性能分析

CS336 Systems

主讲: Aaron

Fudan University

今日摘要

2026.7.18 Nsight Systems 同时记录 CPU 线程、CUDA API、GPU kernel 和 NVTX range。分析时可以先用统计报告确定主要 kernel，再用时间线观察这些 kernel 在 forward、backward、gradient clipping 和 optimizer update 中如何分布。

16.1 Nsight Systems 的分析流程

一次完整分析可以分为两步：

1. 使用 `nsys stats` 汇总大量 kernel，判断时间主要花在哪里；
2. 打开 `.nsys-rep`，在时间线上观察各阶段的顺序、空隙、重叠和同步。

两者回答的问题不同：

工具	主要用途
统计日志	汇总 kernel 的累计时间、调用次数和时间占比
图形界面	执行顺序、阶段边界、GPU 空闲和 CPU-GPU 交互

16.2 生成 Profiling Report

一个基本命令如下：

```
NSYS_NVTX_PROFILER_REGISTER_ONLY=0 \  
uv run nsys profile \  
  --trace=cuda,nvtx \  
  --capture-range=nvtx \  
  --nvtx-capture='profile_region@*' \  
  --capture-range-end=stop \  
  --output=results/example \  

```

```
python -m cs336_systems.benchmark ...
```

最终生成:

```
results/example.nsys-rep
```

其中, `nsys status --environment` 只用于检查当前环境支持哪些 profiling 功能, 并不是查看 `.nsys-rep` 的命令。

16.3 如何读取统计日志

16.3.1 整体 Kernel 汇总

```
nsys stats \  
  --report cuda_gpu_kern_sum \  
  results/example.nsys-rep
```

该报告按照 kernel 名称汇总:

- kernel 累计运行时间;
- 在所有 kernel 时间中的占比;
- 调用次数;
- 平均、最小和最大运行时间。

它适合回答:

- GPU 时间主要花在矩阵乘法还是逐元素运算;
- 哪个 kernel 的累计时间最高;
- 模型或序列变大后, 主要开销是否发生变化。

16.3.2 NVTX 内部的 Kernel 汇总

```
nsys stats \  
  --report nvtx_kern_sum \  
  results/example.nsys-rep
```

该报告把 GPU kernel 归属到相应的 NVTX range, 可用于比较:

```
attention_qk_matmul
```

attention_scale
attention_mask
attention_softmax
attention_av_matmul

统计 attention 时，只对最内层 range 下的 kernel 时间求和，不再重复加入父级 attention 和 forward，否则会产生重复统计。

16.4 如何阅读时间线

图 1 展示了一个完整 train step 在 Nsight Systems 中的时间线。上方是 GPU 硬件活动，下方是 CPU 线程、NVTX range 和 CUDA API。




图 1: XL 模型 train step 的 Nsight Systems 时间线总览。CUDA HW 表示 GPU 实际活动，Python 线程上的 NVTX range 表示代码阶段。

16.4.1 CUDA HW

CUDA HW 表示 GPU 硬件上的实际执行活动。展开 All Streams 后，可以看到不同 CUDA stream 上的 kernel 和 memory operation。

分析 GPU 是否持续工作时，主要观察：

- kernel 是否连续排列；
- kernel 之间是否存在明显空隙；
- 多个 stream 是否发生重叠；
- 某个 NVTX 阶段对应哪些 kernel。

CUDA HW 主要回答：

GPU 在什么时间真正执行了什么工作？

图 2 是 CUDA HW 的局部放大结果。蓝色块表示 GPU kernel，灰色 NVTX range 用于标记这些 kernel 所属的代码阶段。




图 2: CUDA HW 局部放大图。上方蓝色块为 GPU kernel，下方为投影到 GPU 时间线上的 NVTX range。

16.4.2 Python Thread 与 NVTX

Python 主线程上的 NVTX range 表示 Python 代码的阶段边界，例如：

```
forward
backward
clip_gradient
update
```

它的持续时间是 host 侧看到的墙钟时间，其中可能包含：

- CUDA kernel launch;
- Python 与 framework overhead;
- CUDA synchronization;
- 等待此前异步 GPU 工作完成的时间。

因此，Python NVTX range 的长度不能直接理解为该阶段所有 GPU kernel duration 的总和。

16.4.3 CUDA API

CUDA API 轨道显示 CPU 调用的 CUDA runtime 函数，例如：

```
cudaLaunchKernel
```

`cudaMemcpyAsync`
`cudaStreamSynchronize`

长时间的 `cudaStreamSynchronize` 通常表示 CPU 正在等待 GPU 完成此前异步提交的工作，而不是 CPU 自己进行了同样长时间的计算。

16.5 为什么 Backward 可能出现在其他线程

Python 主线程可以调用：

```
loss.backward()
```

但 PyTorch autograd engine 可能让名为

```
pt_autograd_*
```

的工作线程提交部分 backward CUDA kernel。

如果 backward NVTX range 只加在 Python 主线程上，基于线程的关联不一定能把工作线程提交的所有 kernel 都归入该 range。




图 3: Backward 阶段的线程关系。Python 主线程发起 backward，部分 CUDA 工作由 `pt_autograd_*` 线程提交。

分析

这不是 backward 没有执行，也不一定是代码错误。NVTX range 属于创建它的 CPU 线程，而实际 CUDA kernel 可能由其他 autograd 工作线程提交。

因此，判断 backward 是否执行时，还应结合：

- `pt_autograd_*` 工作线程；
- CUDA HW 上的 kernel；
- 完整 train step 的阶段顺序。

16.6 为什么 CUDA HW 下可能出现两个 NVTX 轨道

Nsight Systems 可能在不同 GPU 层级下显示同一组 NVTX range，例如：

- All Streams 对应的聚合视图；
- kernel 或 memory 分类对应的详细视图。

这通常是同一组 NVTX 信息在不同层级下的显示，不表示代码执行了两遍，统计时也不能把两个轨道的时间再次相加。

16.7 三种时间的区别

需要区分以下三个概念：

时间	含义
NVTX wall time	CPU 进入和退出代码 range 之间的时间
GPU projected NVTX time	与该 range 关联的 GPU 活动所覆盖的时间区间
Kernel cumulative time	该 range 下各个 kernel duration 的累计和

如果不同 kernel 在多个 stream 上发生重叠，则：

$$T_{\text{kernel cumulative}} \neq T_{\text{wall}}.$$

因此，应根据问题选择指标：

- 比较用户感受到的步骤延迟：使用同步后的 wall time；
- 分析 GPU 的主要计算开销：使用 kernel summary；
- 分析执行顺序和 GPU 空隙：使用 CUDA HW timeline。

16.8 我们采用的读图顺序

面对一个较大的 Nsight 报告，可以按照以下顺序阅读：

1. 定位 `profile_region`，确认测量范围；
2. 查看 forward、backward、clip gradient 和 update 的阶段边界；
3. 查看 CUDA HW 是否持续有 kernel 执行；
4. 放大感兴趣的阶段；
5. 展开 All Streams，查看主要 kernel；

6. 结合 `cuda_gpu_kern_sum` 和 `nvtx_kern_sum` 做定量比较。