

LLM Notes

2026 Spring

Day 10: CS336 Transformer LM (2)

deeplearning

主讲: Aaron

Fudan University

今日摘要

2026.7.12 完成了 CS336 Assignment 1 中截至 Transformer LM 的编程作业。整理 Transformer 参数量、显存占用与 FLOPs 核算部分的非代码作业。

10.1 作业: Transformer FLOP 核算

定义

定义 10.1.1 (FLOP 与 FLOPS). FLOP 是 Floating-Point Operation 的缩写, 表示一次浮点运算; FLOPs 中的小写 s 可以表示复数, 用于描述完成某项计算所需的浮点运算总量。

FLOPS 或 FLOP/s 表示 Floating-Point Operations Per Second, 即每秒能够完成的浮点运算次数, 用于描述硬件的计算吞吐率。

因此, FLOPs 衡量任务的计算量, 而 FLOP/s 衡量设备的计算速度。

$$T \approx \frac{\text{计算量 (FLOPs)}}{\text{计算吞吐率 (FLOP/s)}}$$

定义

定义 10.1.2 (FLOP). FLOP 表示一次浮点运算, 例如一次浮点加法或乘法。

给定

$$A \in \mathbb{R}^{m \times n}, \quad B \in \mathbb{R}^{n \times p},$$

矩阵乘法 AB 的结果包含 mp 个元素。每个元素需要约 n 次乘法和 n 次加法, 因此总计算量约为

$$2mnp \text{ FLOPs.}$$

本节主要核算 Transformer 中的矩阵乘法。RMSNorm、RoPE、softmax、SiLU、逐

元素乘法和残差加法同样会消耗计算资源，但相较于大型矩阵乘法，它们通常不是本题分析的重点。

10.1.1 问题 (a): 参数量与模型内存

分析

模型配置如下：

$V = 50,257$, 词表大小,
 $S = 1,024$, 上下文长度,
 $L = 48$, Transformer Block 数量,
 $d_{\text{model}} = 1,600$, 模型主干维度,
 $h = 25$, 注意力头数,
 $d_{\text{ff}} = 4,288$. FFN 中间维度

需要回答：

1. 该模型一共有多少个可训练参数？
2. 若每个参数使用 FP32 表示，仅加载模型参数需要多少内存？

multi attn 计算包括 qkv0 的四个映射 $4 * d_{\text{model}}^2 = 10240000$

ffn 为 swiglu 形式包括 3 个变换 $3 * d_{\text{model}} * d_{\text{ff}} = 20582400$

两个 layer norm 层, $2 * d_{\text{model}} = 3200$

参数统计应包括：

- token embedding; $d_{\text{model}} * V = 80411200$
- L 个 Transformer Block; $(10240000 + 20582400 + 3200) * L = 1479628800$
- 最终的 RMSNorm; 1600
- language-model head. $V * d_{\text{model}} = 80411200$

合计 1640452800 约为 1.64B 参数量，所需内存 $1.64 * 4 = 6.58\text{GB}$

10.1.2 问题 (b): 一次前向传播的 FLOPs

假设输入序列长度等于最大上下文长度：

$S = \text{context_length} = 1,024$.

每个 Transformer Block 中需要考虑：

1. Query 投影:

$$XW_Q^\top; (2 * d_{model} * d_{model} * S = 5,242,880,000)$$

2. Key 投影:

$$XW_K^\top; (2 * d_{model} * d_{model} * S = 5,242,880,000)$$

3. Value 投影:

$$XW_V^\top; (2 * d_{model} * d_{model} * S = 5,242,880,000)$$

4. 注意力分数:

$$QK^\top; (2 * S * S * d_{model} = 2 * 1600 * 1600 = 3,355,443,200.)$$

5. 注意力权重与 Value 相乘:

$$AV; (2 * S * S * d_{model} = 2 * 1600 * 1600 = 3,355,443,200.)$$

6. 多头注意力输出投影:

$$HW_O^\top; (2 * d_{model} * d_{model} * S = 5,242,880,000)$$

7. SwiGLU 的两个向上投影:

$$XW_1^\top, (2 * d_{model} * S * d_{ff} = 14,050,918,400.) \quad XW_3^\top; (2 * d_{model} * S * d_{ff} = 14,050,918,400.)$$

8. SwiGLU 的向下投影:

$$X_{ff}W_2^\top. (2 * d_{model} * S * d_{ff} = 14,050,918,400.)$$

整个语言模型还需要考虑最终的 vocabulary projection:

$$XW_{lm-head}^\top. (2 * d_{model} * B * vocab_{size} = 160822400)$$

分析

求和得到了单个的 block 需要 69.84 GFLOPs., 乘以 48 外加最后的语言头, 得到一共是 $3.52 * 10^{12} FLOPs$, as well as $3.52 TFLOPs$

备注

Embedding 通常作为查表操作，不计作矩阵乘法。提交内容应包含矩阵乘法列表、每类操作的 FLOPs，以及总 FLOPs。

10.1.3 问题 (c)：主要计算开销来自哪里？**分析**

主要计算量在 ffN

10.1.4 问题 (d)：比较不同规模的 GPT-2

统一使用

$$V = 50,257, \quad S = 1,024,$$

并将

$$d_{\text{ff}} \approx \frac{8}{3} d_{\text{model}}$$

取为最接近的 64 的整数倍。各模型配置为：

模型	L	d_{model}	h	d_{ff}
GPT-2 Small	12	768	12	2,048
GPT-2 Medium	24	1,024	16	2,752
GPT-2 Large	36	1,280	20	3,392
GPT-2 XL	48	1,600	25	4,288

各部分 FLOPs 为

$$F_{\text{proj}} = 8LSd_{\text{model}}^2,$$

$$F_{\text{attn}} = 4LS^2d_{\text{model}},$$

$$F_{\text{FFN}} = 6LSd_{\text{model}}d_{\text{ff}},$$

以及

$$F_{\text{vocab}} = 2Sd_{\text{model}}V.$$

计算结果如下：

模型	Attention 投影	Attention 矩阵	SwiGLU FFN	Vocabulary 投影	总 FLOPs
Small	19.88%	13.25%	39.76%	27.10%	0.292 TFLOPs
Medium	24.83%	12.42%	50.05%	12.70%	0.830 TFLOPs
Large	27.32%	10.93%	54.30%	7.45%	1.769 TFLOPs
XL	28.62%	9.16%	57.53%	4.68%	3.517 TFLOPs

分析

在固定词表大小和上下文长度的情况下，随着模型深度和 d_{model} 增大，SwiGLU FFN 与 attention projection 在总 FLOPs 中的占比逐渐上升，而 attention 矩阵计算和 vocabulary projection 的占比逐渐下降。主要原因是模型内部线性层的计算量近似随 Ld_{model}^2 增长，而 vocabulary projection 不随层数 L 增长，attention 矩阵计算在固定序列长度下也只随 Ld_{model} 线性增长。

10.1.5 问题 (e): 拓展上下文长度

分析

当上下文长度从 1,024 增加至 16,384 时，序列长度扩大了 16 倍。Attention projection、SwiGLU FFN 和 vocabulary projection 均随 S 线性增长，因此 FLOPs 扩大 16 倍； QK^T 与 AV 随 S^2 增长，因此 FLOPs 扩大 256 倍。

新的各部分 FLOPs 为

$$F_{\text{proj}} = 16.11 \text{ TFLOPs},$$

$$F_{\text{attn}} = 82.46 \text{ TFLOPs},$$

$$F_{\text{FFN}} = 32.37 \text{ TFLOPs},$$

$$F_{\text{vocab}} = 2.63 \text{ TFLOPs}.$$

因此，总计算量由

$$3.52 \text{ TFLOPs}$$

增加至

$$133.58 \text{ TFLOPs},$$

约为原来的 38.0 倍。Attention 矩阵计算的占比由 9.16% 上升至 61.73%，成为长上下文条件下最主要的计算开销；SwiGLU FFN 的占比则由 57.53% 降至 24.24%。