

LLM Notes

2026 Spring

Day 3: RMSNorm 与 SELU

deeplearning 基础

主讲: Aaron

Fudan University

今日摘要

今天浅述 RMSNorm 和 SELU 激活函数，也是简单明快的内容。

3.1 RMS Norm

相比 Layer Norm, RMSNorm 认为求均值的步骤可以忽略（默认均值为 0），同时可学习的偏置也自然可以忽略

定义

定义 3.1.1 (Root Mean Square Normalization). 对于输入向量 $\mathbf{x} \in \mathbb{R}^H$, RMSNorm 首先计算其均方根 (RMS):

$$\text{RMS}(\mathbf{x}) = \sqrt{\frac{1}{H} \sum_{i=1}^H x_i^2 + \epsilon},$$

然后，归一化输出为:

$$\text{RMSNorm}(\mathbf{x}) = \frac{\mathbf{x}}{\text{RMS}(\mathbf{x})} \odot \gamma,$$

其中 $\gamma \in \mathbb{R}^H$ 是一个可学习的缩放参数（向量），用于恢复模型的表达能力。

3.1.1 针对 (B, S, H) 张量的操作细节

在 PyTorch 等框架中，Transformer 的输入张量形状通常为 (B, S, H)，其中：

- **B (Batch Size)**: 批次大小；
- **S (Sequence Length)**: 序列长度（即 token 数量）；
- **H (Hidden Dimension)**: 隐藏层维度（即每个 token 的特征向量长度）。

对于这种三维张量，RMSNorm 的归一化操作是在**最后一个维度（H 维度）上独立进行的**。也就是说，对于 batch 中的每一个样本 b 和序列中的每一个位置 s ，我们取其对应的长度为 H 的向量 $\mathbf{x}_{b,s} \in \mathbb{R}^H$ ，并对其计算 RMS 值并归一化：

$$\text{RMSNorm}(\mathbf{x}_{b,s}) = \frac{\mathbf{x}_{b,s}}{\text{RMS}(\mathbf{x}_{b,s})} \odot \gamma.$$

关键点：这相当于对 (B, S) 中的每一个位置，都使用**自己独立的** RMS 值进行归一化，但所有位置共享同一个可学习的缩放参数 $\gamma \in \mathbb{R}^H$ 。

备注

与 Batch Norm 的本质区别：Batch Norm 是在**批次维度 (B)** 上计算统计量，其行为依赖于 batch 中的其他样本；而 RMSNorm（以及 Layer Norm）是在**特征维度 H** 上计算统计量，与 batch 大小无关，因此更适用于序列长度可变、batch size 较小的场景。

3.2 SELU

SELU 是一种自带归一化的激活函数。

定义

定义 3.2.1 (SELU).

$$\text{SELU}(x) = \lambda \begin{cases} x & x > 0 \\ \alpha(e^x - 1) & x \leq 0 \end{cases} \quad \text{其中 } \lambda \approx 1.0507, \alpha \approx 1.6733$$

分析

归一化的关键在于 λ 和 α 两个固定常数。它们是通过数学推导得出的唯一解，使得对于**零均值、单位方差**的输入，SELU 的输出也**近似保持零均值、单位方差**。

限制：自归一化性质仅对**顺序网络**成立（即前馈全连接或 CNN，无跳跃连接），在含有残差连接、使用 dropout 的情况下，完全不成立，该激活函数已经因此不在现代 LLM 框架中使用。