

LLM Notes

2026 Spring

Day 7: Confident Learning

deeplearning

主讲: Aaron

Fudan University

今日摘要

2026.7.9 学习的内容和 mit 的 DCAI 课程相关, 介绍一下今天学习到的置信学习。置信学习是一种系统性的框架, 用于识别标签错误、刻画标签噪声, 并在带噪数据上重新训练模型。其核心思想是: 不直接修复错误标签, 而是估计噪声标签与真实标签的联合分布, 据此找出并过滤错误样本。

7.1 置信学习 (Confident Learning)

定义

定义 7.1.1 (Confident Learning). 设:

- $\tilde{y} \in \{1, \dots, m\}$: 观测到的噪声标签 (可能存在错误的人工标注);
- $y^* \in \{1, \dots, m\}$: 未知的真实标签;
- n : 样本总数;
- m : 类别总数。

置信学习的目标是估计噪声标签与真实标签的联合分布 $\mathbf{Q}_{\tilde{y}, y^*}$, 其中:

$$\mathbf{Q}_{i,j} = p(\tilde{y} = i, y^* = j)$$

即: 样本被标注为类别 i 、但实际上属于类别 j 的概率。

7.1.1 Step 1: Count —— 估计联合分布

具体步骤如下:

Step 1.1: 交叉验证获取预测概率

- 对数据集进行 k 折交叉验证, 得到每个样本 i 对每个类别 j 的预测概率 $\hat{p}_{i,j} =$

$P(\text{真实类别} = j \mid \mathbf{x}_i)$ 。

Step 1.2: 计算置信度阈值对于每个类别 j ，计算其置信度阈值：

$$t_j = \frac{1}{n_j} \sum_{i: \hat{y}_i = j} \hat{p}_{i,j}$$

即类别 j 中所有样本预测为 j 的概率的平均值。

Step 1.3: 构建计数矩阵 $\mathbf{C}_{\hat{y}, y^*}$ 对于每个样本 i ，若 $\hat{p}_{i,j} \geq t_j$ ，则将样本 i “计数”为属于类别 j 。计数矩阵 $\mathbf{C}_{i,j}$ 表示：被标注为类别 i 、但被“计数”为类别 j 的样本数量。

$$\mathbf{C}_{i,j} = \left| \left\{ \mathbf{x} \in \mathbf{X}_{\hat{y}=i} : \arg \max_{j'} \hat{p}_{\mathbf{x},j'} = j \right\} \right|$$

Step 1.4: 标定计数矩阵为使分类计数总和与实际分类总数一致，对标定后的计数矩阵进行修正：（使得真实标签和预测标签的边缘分布一致）

$$\hat{\mathbf{C}}_{i,j} = \mathbf{C}_{i,j} \cdot \frac{\sum_{j'} \mathbf{C}_{i,j'}}{\sum_{j'} \mathbf{C}_{j',i}}$$

Step 1.5: 估计联合分布（矩阵归一化）

$$\mathbf{Q}_{i,j} = \frac{\hat{\mathbf{C}}_{i,j}}{\sum_{i',j'} \hat{\mathbf{C}}_{i',j'}}$$

Example

示例：假设数据集有狗、狐狸、牛三类，计数矩阵 $\mathbf{C}$ （未归一化）为：

$$\mathbf{C} = \begin{bmatrix} 100 & 40 & 20 \\ 56 & 60 & 24 \\ 32 & 12 & 56 \end{bmatrix}$$

其中第 1 行第 2 列表示：被标注为“狗”、但实际更像“狐狸”的样本有 40 个。

7.1.2 Step 2: Clean ——过滤错误样本

在得到联合分布 $\mathbf{Q}$ 后，可采用以下几种方法过滤错误样本：

1. **Method 1 ($C_{\text{confusion}}$)**: 选取最大预测概率对应的类别与人工标签不一致的样本过滤；
2. **Method 2 ($\mathbf{C}_{\hat{y}, y^*}$)**: 选取进入计数矩阵 $\mathbf{C}$ 非对角单元的样本过滤；

3. **Method 3 (PBC)**: 对每个类别 i , 选取 $n_i \cdot \sum_{j \neq i} \mathbf{Q}_{i,j}$ 个最低置信度样本过滤;
4. **Method 4 (PBNR)**: 对 $\mathbf{Q}$ 的每个非对角单元, 选取对应数量的最大间隔样本过滤;
5. **Method 5 (C+NR)**: 同时采用 Method 3 和 Method 4。

7.1.3 Step 3: Re-Training —重新训练

过滤掉错误样本后, 可根据联合分布 $\mathbf{Q}$ 调整每个类别的损失权重:

$$w_i = \frac{\sum_j \mathbf{Q}_{i,j}}{\sum_j \mathbf{Q}_{j,i}}$$

然后使用调整后的权重, 配合 **Co-Teaching** 等带噪学习方法重新训练模型。